

Relatório Técnico

Título: Desenvolvimento de Assistente Virtual Médico com RAG e Fine-Tuning de LLM – Tech Challenge

Integrante: Charles Andrews William Kulkauskis – Grupo 71 (Individual)

Vídeo: <https://youtu.be/MKxs-5ga4d8>

Repositório: <https://github.com/charleskulkauskis/fiap-tech-challenge-fase-3>

Disciplina: Fase 3 - Pós Tech 7IADT

1. Introdução

Este relatório descreve a implementação de um sistema inteligente capaz de auxiliar condutas clínicas utilizando inteligência artificial generativa, processamento de dados estruturados e recuperação de informações baseada em documentos internos.

2. Metodologia de Fine-Tuning

Foi utilizado o modelo base **Phi-3.5-mini-instruct** devido a sua capacidade de ser interpretado pelo Colab, através da biblioteca **Unsloth**. A técnica de **4-bit quantization** e **LoRA** permitiu o ajuste fino do modelo no dataset MedPT, otimizando o vocabulário médico e a precisão das respostas clínicas.

3. Arquitetura do Sistema

O sistema utiliza **LangGraph** para coordenar dois estados principais:

- **Recuperação (RAG):** Consulta vetorial no **ChromaDB** para buscar protocolos hospitalares.
- **Geração:** O modelo fine-tuned processa o contexto recuperado e os dados (anonimizados) do paciente para sugerir uma conduta.

4. Segurança e Ética

Em conformidade com a LGPD e normas médicas:

- **Anonimização:** Algoritmos de Regex removem PII (Personal Identifiable Information) antes do processamento.
- **Auditabilidade:** Implementação de logging detalhado para cada ação do agente.

- **Disclaimer:** Todas as saídas incluem a obrigatoriedade de validação por um médico humano.

5. Resultados

O modelo demonstrou alta capacidade de síntese, integrando informações de múltiplas fontes (prontuários e manuais médicos) e mantendo a coerência técnica sem alucinações críticas, graças ao controle de temperatura (0.7) e restrição de contexto.

É possível que ele se perca um pouco na resposta, o que fez necessário explicitar sempre a consulta final de um humano, devido a construção e escolha de parâmetros e modelo para rodar final de um humano, devido aos padrões do script.